

교과목 2 : 데이터 분석과 머신러닝 / 딥러닝

단원 3 : 딥러닝

DAY1. 딥러닝 이해 및 프레임워크 설치

목 차

1. 인공지능과 딥러닝의 이해		3
2. 인공신경망의 원리		16
3. 딥러닝이 발전한 이유		17
4. 딥러닝 활용 분야		19
5. 딥러닝 프레임워크		22
6. DNN 모델 예제 분석		25


1. 인공지능과 딥러닝의 이해

1.1 인공지능의 개념

인공지능(Artificial Intelligence, AI)은 인간의 지능적인 행동을 컴퓨터가 수행하도록 만드는 기술을 의미한다. 인간은 눈으로 사물을 보고, 귀로 소리를 듣고, 과거 경험을 바탕으로 판단을 내릴 수 있다. 인공지능은 이러한 인간의 인지 능력을 컴퓨터 시스템으로 구현하기 위해 연구되는 학문 분야이다.

초기의 인공지능은 사람이 직접 규칙을 작성하여 문제를 해결하는 방식이었다. 예를 들어 체스 프로그램을 개발할 경우 가능한 모든 수를 규칙으로 작성하여 컴퓨터가 선택하도록 만들었다. 하지만 현실 세계의 문제는 너무 복잡하여 모든 규칙을 사람이 직접 정의하기 어렵다. 이러한 한계를 극복하기 위해 머신러닝과 딥러닝 기술이 등장하게 되었다.

오늘날 인공지능은 스마트폰 음성 비서, 번역 시스템, 자율주행 자동차, 의료 영상 분석, 금융 예측, 추천 시스템 등 다양한 분야에서 활용되고 있다.




(출처: 엔비디아 블로그)

Artificial Intelligence
Any technique which enables computers to mimic human behavior.

Machine Learning
Subset of AI techniques which use statistical methods to enable machines to improve with experiences.

Deep Learning
Subset of ML which make the computation of multi-layer neural networks feasible.



(출처: rapid miner)

그림은 AI가 머신러닝, 딥러닝을 포함하는 가장 큰 개념임을 보여준다.


일반적으로 AI는 다음과 같은 능력을 포함한다.

- 학습(Learning)
- 추론(Reasoning)
- 문제 해결(Problem Solving)
- 의사결정(Decision Making)
- 언어 이해(Language Understanding)
- 시각 인식(Computer Vision)

위키피디아 정의에 따르면 인공지능은 인간의 인지 기능(Cognitive Function)을 모방하는 기술이다. 예를 들어 사람은 고양이를 보고 즉시 고양이라고 인식하지만, 컴퓨터는 이러한 능력이 없기 때문에 학습을 통해 고양이를 식별하는 방법을 배워야 한다.


1.2 머신러닝의 개념

머신러닝(Machine Learning)은 인공지능의 하위 분야이며, 컴퓨터가 데이터를 통해 스스로 규칙을 학습하는 기술이다. 기존 프로그래밍은 사람이 규칙을 작성해야 했지만 머신러닝은 데이터를 입력하면 컴퓨터가 패턴을 찾아 학습한다.



사람은 다음과 같은 특징을 추출하여 고양이를 구분하려 한다.

- 귀
- 눈
- 코
- 발바닥



그러나 실제 이미지에서는

- 고양이 자세가 다름
- 털 색상이 다름
- 조명이 다름
- 배경이 다름

등의 문제가 발생한다.

따라서 사람이 규칙을 하나하나 만드는 것은 거의 불가능하다.

그림은 전통적인 컴퓨터 비전(Computer Vision)의 어려움을 설명하는 대표적인 예시이다.

예를 들어 고양이와 강아지를 구분하는 프로그램을 만든다고 가정하자. 전통적인 방식에서는 귀 모양, 눈 모양, 털 색깔 등을 사람이 규칙으로 정의해야 한다.

기존 프로그래밍은 다음과 같다.

입력 데이터 + 규칙(프로그램) → 결과


예를 들어 고양이를 판별하려면 다음과 같은 규칙을 사람이 직접 작성해야 한다.

- 귀가 삼각형인가?
- 수염이 있는가?
- 꼬리가 있는가?
- 네 발로 걷는가?

하지만 실제 세상에서는 고양이의 종류가 매우 많고 다양한 모습이 존재하기 때문에 모든 규칙을 사람이 직접 작성하기 어렵다.

이러한 문제를 해결하기 위해 등장한 기술이 머신러닝이다.

머신러닝에서는 수천 장의 고양이 사진과 강아지 사진을 학습시켜 컴퓨터가 스스로 특징을 발견하도록 만든다.



머신러닝에서는 사람이 규칙을 만드는 것이 아니라 컴퓨터가 데이터를 보고 규칙을 스스로 학습한다.

예를 들어 다음과 같은 데이터를 제공한다.

- 고양이 이미지 10,000장
- 개 이미지 10,000장

컴퓨터는 이미지의 특징을 분석하여 "고양이 판별 함수"를 생성한다.

이미지를 입력하면 머신러닝 모델은 내부적으로 특징(Feature)을 추출한다.

예를 들어

- 귀 모양
- 얼굴 형태
- 눈 위치
- 몸체 비율

등을 수치화한다.

그리고 학습된 분류기(Classifier)가 최종적으로 결과를 출력한다.

고양이일 확률 : 95%

개일 확률 : 5%

와 같이 결과를 반환하게 된다.

즉,

데이터 → 머신러닝 알고리즘 → 학습된 모델


이라는 과정이 수행된다.

이렇게 만들어진 모델은 새로운 이미지가 입력되었을 때 고양이인지 아닌지를 예측할 수 있다.

머신러닝은 크게 지도학습(Supervised Learning), 비지도학습(Unsupervised Learning), 강화학습(Reinforcement Learning)으로 구분된다.

Supervised


Learning
known
patterns



(위의 고양이판별 예시에 해당)

Unsupervised

Learning
unknown
patterns



Reinforcement

Generating data
Learning patterns



(출처: <http://adagefficiency.com>)

1.3 딥러닝의 개념

딥러닝(Deep Learning)은 머신러닝의 한 분야로서 인공신경망(Artificial Neural Network)을 기반으로 한다. 특히 여러 개의 은닉층(Hidden Layer)을 포함하는 심층 신경망을 사용하기 때문에 "Deep" Learning이라고 부른다.

인공신경망은 인간의 뇌 신경세포(Neuron)를 모방하여 만들어졌다.

신경망의 기본 구조는 다음과 같다.

입력층(Input Layer)

→ 은닉층(Hidden Layer)

→ 출력층(Output Layer)

딥러닝이 기존 머신러닝과 다른 점은 특징 추출 과정을 자동화한다는 것이다.

기존 머신러닝

사람이 특징 추출

→ 알고리즘 학습

딥러닝

특징 추출 + 학습

→ 모두 자동 수행

따라서 이미지, 음성, 자연어 처리 분야에서 매우 뛰어난 성능을 보인다.

딥러닝은 사람이 특징을 추출하지 않아도 데이터로부터 자동으로 특징을 학습할 수 있다. 이러한 특성 덕분에 이미지 인식, 음성 인식, 자연어 처리 분야에서 혁신적인 성과를 이루었다.


대표적인 딥러닝 모델에는 CNN, RNN, LSTM, Transformer, GAN 등이 있다.



딥러닝 발전 과정을 다음과 같이 표현한다.

시대	AI의 역할
1980년대	데이터 분류
1990년대	패턴 인식
2000년대	이미지·음성 인식
2010년대	객체 검출 및 자연어 처리
2020년대	생성형 AI
현재	멀티모달 AI

"과거 AI는 데이터를 분석하는 기술이었다면, 현재 AI는 보고(Vision), 듣고(Audio), 이해하고(Language), 생성하는(Creation) 기술로 진화하였다."



1. McCulloch & Pitts
뉴런의 수학적 모델 구현 (1943)



2. Rosenblatt 최
초의 컴퓨터 시뮬레
이션 (1969)



3. Hinton
근대 딥러닝의 부활
(1995)

딥러닝(Deep Learning)의 역사와 발전 과정(계보)을 보여주는 대표적인 인물들을 정리한 그림이다. 이 세 사람은 오늘날 ChatGPT, 자율주행차, 이미지 생성 AI, 음성인식 AI 가 등장할 수 있도록 만든 중요한 연구자들이다.

딥러닝의 계보란?

계보(系譜)란 기술이 어떻게 발전해 왔는지를 시간 순서대로 정리한 것이다.

쉽게 말하면,

인공신경망의 탄생

↓

퍼셉트론 개발

↓

딥러닝 부활

↓

현재 ChatGPT

의 흐름을 의미한다.

1 단계 : 워런 맥컬록(Warren McCulloch)과 월터 피츠(Walter Pitts) (1943)

이들은 1943 년에 최초로 인간 뇌의 뉴런(Neuron)을 수학적으로 표현하였다.

왜 중요한가?

인간의 뇌에는 약 1,000 억 개의 뉴런이 존재한다.

뉴런은 다음과 같이 동작한다.

정보 입력

↓

판단

↓

신호 출력

McCulloch 와 Pitts 는 "뉴런도 수학식으로 표현할 수 있지 않을까?"라는 생각을 하였다.
그래서 최초의 인공 뉴런 모델을 만들었다.

초보자 비유

전등 스위치를 생각해 보자.

입력 = OFF

출력 = 0

입력 = ON

출력 = 1

뉴런도 비슷하다.

신호가 충분히 강함

→ 1 출력

신호가 약함

→ 0 출력

이 개념이 오늘날 모든 인공지능망의 시작이 되었다.

McCulloch-Pitts 뉴런 구조

가장 간단하게 표현하면

$$y = f(\sum_i w_i x_i + b)$$

이다.

여기서

- x = 입력값
- w = 중요도(가중치)
- b = 편향
- f = 활성화 함수
- y = 출력값

이다. 현재의 딥러닝도 기본적으로 이 구조를 사용한다.

2 단계 : 프랭크 로젠블랫 (Frank Rosenblatt) (1958~1969)

그는 최초의 학습 가능한 인공지능망인 **Perceptron**(퍼셉트론) 개발하였다.

퍼셉트론이란?

McCulloch 와 Pitts 는 "뉴런을 만들 수 있다"를 보여주었다.

Rosenblatt 는 "뉴런이 스스로 학습할 수 있다"를 보여주었다.

엄청난 차이이다.

예시

컴퓨터에게

○ = 원

□ = 사각형

△ = 삼각형

을 계속 보여준다.

그러면 퍼셉트론은

원 특징 학습

사각형 특징 학습

삼각형 특징 학습

을 수행한다.

결국, 새로운 원을 보여줘도 "이건 원입니다."라고 판단할 수 있게 된다.

왜 혁신적이었는가?

당시에는

사람이 규칙 작성

↓

컴퓨터 실행 방식이었다.

퍼셉트론은 데이터 제공

↓

컴퓨터가 스스로 규칙 학습을 수행하였다.

현재 머신러닝의 시작점이라고 볼 수 있다.

하지만 문제도 있었다

1969 년 마빈 민스키 (Marvin Minsky) 와 시모어 페퍼트 (Seymour Papert) 는 퍼셉트론이 XOR 문제를 해결할 수 없다는 사실을 발표하였다.

예를 들어

0 XOR 0 = 0

0 XOR 1 = 1

1 XOR 0 = 1

1 XOR 1 = 0

이 문제는 단일 퍼셉트론으로 해결할 수 없었다.

그 결과 인공지능 연구는 약 20 년 동안 침체기에 들어간다. 이를 AI Winter(인공지능 겨울)이라고 부른다.

3 단계 : 제프리 힌턴 (Geoffrey Hinton) (1995)

그는 "딥러닝의 아버지"라고 불린다.

Hinton 은 무엇을 했는가?

그는 "은닉층(Hidden Layer)을 여러 개 사용하면 어떨까?"라는 생각을 하였다.

즉, 기존 구조

입력

↓

출력을 입력

↓

은닉층

↓

은닉층

↓

은닉층

↓

출력

로 확장하였다.

이것이 바로 **Deep Neural Network (DNN)** 이다.

왜 딥(Deep)인가?

Deep 은 "깊다" 라는 뜻이다.

은닉층이 많아질수록

얕은 신경망

↓

깊은 신경망이 된다.

예를 들어 고양이 사진을 학습한다고 생각해 보자.

첫 번째 층

선(Line)을 학습

—
|
\
/

두 번째 층

모서리(Corner)를 학습

┐
└
┌

세 번째 층

눈, 귀 등을 학습

눈
귀
코

네 번째 층

고양이 얼굴 학습

고양이 얼굴

최종 층

고양이 라고 판단

Hinton 이후 발생한 변화

2012 년 AlexNet 이 등장하면서 이미지 인식 정확도가 폭발적으로 향상되었다.

이후

- CNN
- RNN
- LSTM
- Transformer

가 등장하였다.

그리고 현재는

- ChatGPT
- Gemini
- Claude
- Stable Diffusion
- Midjourney

같은 생성형 AI 까지 발전하였다.

딥러닝 계보

1943

McCulloch & Pitts

↓

최초 인공 뉴런

1958~1969

Rosenblatt

↓

퍼셉트론

(학습 가능)

1969~1990

AI Winter

↓

침체기

1995~

Hinton

↓

딥러닝 부활

2012

AlexNet

↓

딥러닝 폭발적 성장

2020~

Transformer

↓

ChatGPT

현재

생성형 AI 시대

"인공 뉴런의 탄생 → 학습 가능한 신경망 → 딥러닝 부활 → 생성형 AI 시대"

2. 인공신경망의 원리

2.1 인간의 뇌와 인공신경망

인공신경망은 인간의 뇌 구조를 모방하여 설계되었다. 인간의 뇌는 수천억 개의 뉴런이 서로 연결되어 정보를 전달한다. 딥러닝의 뉴런도 입력값을 받아 계산을 수행하고 결과를 다음 계층으로 전달한다.

2.2 퍼셉트론

퍼셉트론(Perceptron)은 가장 기본적인 인공신경망 모델이다.

입력값 x_1, x_2, x_3 와 가중치 w_1, w_2, w_3 를 곱한 후 모두 더하여 출력값을 계산한다.

$$y = w_1x_1 + w_2x_2 + w_3x_3 + b$$

여기서 b 는 편향(Bias)이다.

퍼셉트론은 간단한 분류 문제를 해결할 수 있지만 XOR 문제를 해결할 수 없는 한계가 있다.

2.3 다층 퍼셉트론

XOR 문제를 해결하기 위해 은닉층을 추가한 다층 퍼셉트론(Multi Layer Perceptron, MLP)이 등장하였다.

다층 퍼셉트론은 입력층, 은닉층, 출력층으로 구성된다.

입력층 → 은닉층 → 출력층

은닉층이 많아질수록 복잡한 패턴을 학습할 수 있게 된다.

2.4 활성화 함수

신경망에서는 비선형 문제를 해결하기 위해 활성화 함수를 사용한다.

대표적인 활성화 함수는 다음과 같다.

- Sigmoid
- Tanh
- ReLU
- Leaky ReLU
- Softmax

현재 가장 많이 사용되는 함수는 ReLU이다.

3. 딥러닝이 발전한 이유

3.1 빅데이터의 등장



(출처:luluafrikani.wordpress.com)

인터넷과 스마트폰의 발전으로 엄청난 양의 데이터가 생성되었다.

예)

- 유튜브 영상
- SNS 게시글
- 사진
- 음성 데이터

이러한 데이터는 딥러닝 학습에 매우 중요한 역할을 한다.

3.2 GPU의 발전



(출처:http://wccftech.com)

GPU(Graphics Processing Unit)는 수천 개의 연산 코어를 가지고 있어 대량의 행렬 연산을 병렬로 처리할 수 있다.

딥러닝은 행렬 곱셈 연산을 반복 수행하므로 GPU의 성능 향상이 딥러닝 발전에 결정적인 역할을 하였다.

3.3 알고리즘 발전

대표적인 딥러닝 알고리즘은 다음과 같다.

- CNN
- RNN
- LSTM
- Transformer
- GAN

이러한 알고리즘의 발전으로 다양한 문제를 효과적으로 해결할 수 있게 되었다.

4. 딥러닝 활용 분야

4.1 컴퓨터 비전


컴퓨터 비전은 컴퓨터가 이미지를 이해하도록 만드는 기술이다.

주요 응용 분야는 다음과 같다.

- 얼굴 인식
- 의료 영상 분석
- 객체 탐지
- 자율주행



(출처: Mask R-CNN)



(출처: Marl/O)

4.2 자연어 처리

자연어 처리(NLP)는 인간 언어를 이해하는 기술이다.

활용 예시는 다음과 같다.

- ChatGPT
- 번역기
- 음성 비서
- 문서 요약

4.3 음성 인식

음성을 텍스트로 변환하거나 텍스트를 음성으로 생성하는 기술이다.


대표 사례는 스마트 스피커와 AI 비서이다.

4.4 생성형 AI

생성형 AI는 새로운 콘텐츠를 생성하는 기술이다.

- ChatGPT
- Claude
- Gemini
- Stable Diffusion
- Midjourney

등이 대표적이다.



(출처: CycleGAN)



Original photo

Reference photo

Result

(출처: Deep Photo Style Transfer)

인공지능은 가장 큰 개념이며, 그 안에 머신러닝이 존재하고, 머신러닝 안에 딥러닝이 존재한다. 구조를 나타내면 다음과 같다.

AI

└ Machine Learning

└ Deep Learning

딥러닝의 핵심은 인공신경망을 사용하여 데이터의 특징을 자동으로 학습하는 것이다.

대표적인 딥러닝 모델은 다음과 같다.

- CNN : 이미지 처리
- RNN : 순차 데이터 처리

- LSTM : 시계열 데이터 처리
- Transformer : 자연어 처리 및 생성형 AI
- GAN : 이미지 생성
- AutoEncoder : 차원 축소 및 특징 추출

현재 딥러닝은 컴퓨터 비전, 자연어 처리, 음성 인식, 로봇공학, 자율주행, 의료 AI 등 다양한 분야에서 핵심 기술로 활용되고 있으며, 앞으로도 AI 산업의 중심 기술로 자리잡을 것으로 전망된다.

5. 딥러닝 프레임워크

5.1 딥러닝 프레임워크란

딥러닝 프레임워크는 신경망을 쉽게 구현하고 학습할 수 있도록 제공되는 소프트웨어 라이브러리이다.

대표 프레임워크는 다음과 같다.

- TensorFlow
- Keras
- PyTorch

5.2 TensorFlow

TensorFlow는 Google이 개발한 프레임워크이다.

대규모 서비스와 배포에 강점을 가진다.

5.3 PyTorch

PyTorch는 Meta(Facebook)가 개발한 프레임워크이다.

연구와 교육 분야에서 가장 많이 사용된다.

장점은 다음과 같다.

- 직관적인 문법
- 동적 그래프
- 디버깅 편의성
- 풍부한 커뮤니티

5.4 CPU와 GPU 차이

CPU는 순차 처리에 강하다.

GPU는 병렬 처리에 강하다.

딥러닝 학습은 GPU를 사용할 경우 수십 배 이상 빨라질 수 있다.

5.5 CUDA

CUDA는 NVIDIA가 개발한 병렬 컴퓨팅 플랫폼이다.

GPU를 활용한 딥러닝 학습을 가능하게 한다.

5.6 cuDNN

cuDNN은 딥러닝 전용 GPU 라이브러리이다.

CNN, RNN 등의 연산을 최적화하여 학습 속도를 향상시킨다.

5.7 실습 환경 점검

GPU 확인

```
import torch
print(torch.cuda.get_device_name(0))
```

Tensor 생성

```
import torch
x = torch.tensor([1,2,3])
print(x)
```

GPU 연산 테스트

```
device = "cuda"
x = torch.tensor([1,2,3]).to(device)
print(x)
```

GPU 메모리로 데이터가 이동한 것을 확인할 수 있다.

5.8 딥러닝 개발 환경 구성

개발 환경은 다음 순서로 구성한다.

- Python 설치
- Anaconda 설치
- CUDA 설치
- cuDNN 설치
- PyTorch 설치
- Jupyter Notebook 또는 Google Colab 실행

6. DNN 모델 예제 분석

6.1 DNN으로 집값 예측하기

1) 보스턴 시내




- 미국 보스턴의 집값은 예측이 어려움

2) 보스턴 집값 Dataset(1978년 기준)

(1) 보스턴 집값 정보 데이터

- Kaggle에서 제공하고 있음(www.kaggle.com)
 - 기계학습을 위해 사용하는 dataset을 무료로 제공하는 사이트(Google 소유)
 - 지구상 가장 많은 Open source bigdata 소유
 - 각종 대회를 열어 국제적인 머신러닝 스타 발굴
- 1978년 보스턴 교외 504개 동네의 평균 집값 정보
- 각 동네마다 집값에 영향을 미치는 13개의 요소 제공



2) 보스턴 집값 Dataset(1978년 기준)

본격적으로 기계학습을 시작하기 전에 사용할 dataset을
자세히 들여다보고 연구하는 것은 중요함

“인공지능은 domain knowledge, 즉 **‘특정 분야의 지식’**의 유무가
이 기술의 성패를 좌지우지한다.”

- 내가 풀고 있는 문제와 그에 사용되는 data에 대한 사전 지식이
얼마나 있느냐

3) 보스턴 집값 Dataset 세부 사항

(1) 504행, 13열

- CRIM: 범죄율
- ZN: 25,000 평방피트를 (약 700평) 초과하는 거주지역 비율
- INDUS: 비소매 상업지역 면적 비율
- CHAS: 찰스강의 경계에 위치한 경우, 1 혹은 0
- NOX: 일산화질소 농도
- RM: 주택당 방 수
- AGE: 1940년 이전에 건축된 주택의 비율
- DIS: 직업센터의 거리
- RAD: 방사형 고속도로까지의 거리
- TAX: 재산세율
- PTRATIO: 학생/교사 비율
- LSTAT: 인구 중 저소득층 비율

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	LSTAT
평균 주택가격이 높음	0.58	20	3.9	0	0.57	8.29	67	2.42	5	264	13	7.44
평균 주택가격이 낮음	38.3	0	18.1	0	0.69	5.45	100	1.48	24	666	20.2	30.5


집값




1) 상자그림(Box Plot)

(1) 데이터의 특징을 잘 요약해 주는 5가지 값의 시각적 표현

- 사분위수 (Q1, 중앙값, Q3)와 최솟값, 최댓값




2) 보스턴 집값 Dataset 상자그림




3) 산포도 (Scatter Plot)

(1) 직각 좌표계에서 두 변수에 대응하는 관측값을 점들로 표시한 그림

- 어떤 자료의 흩어진 정도를 나타내는 수치
- 자료의 자세한 분석 및 다음 상황의 예상, 전략 세울 때 사용



4) 보스턴 집값 Dataset 산포도(Y축: MEDV)



1) Pandas 데이터 프레임

(1) 2차원테이블에 특화된 구조

- Numpy 행렬과 호환

The diagram illustrates a 2D table structure with rows and columns. The columns are labeled 'Name', 'Score', 'Attempts', and 'Qualify'. The rows are indexed from 0 to 4. The data is as follows:

	Name	Score	Attempts	Qualify
0	Anastasia	12.5	1	yes
1	Dima	9.0	3	no
2	Katherine	16.5	2	yes
3	James	NaN	3	no
4	Emily	9.0	2	no

Arrows indicate the mapping from the 'Rows' label to the row indices (0-4) and from the 'Columns' label to the column headers. A green box highlights the data area, and an arrow points to the 'Data' label.

2) Z-점수 정규화

- (1) 머신러닝 알고리즘
 - 데이터의 특정패턴을 찾음
 - 새로운 값을 예측
- (2) 넓은 범위 요소의 영향
 - 기계학습을 할 때 범위가 더 넓은 요소가 큰 영향을 미침
 - 범위가 작은 요소는 의미가 거의 묻혀 버림

‘제트점수 정규화 진행 이유’

- (3) $Z\text{-점수} = (X - \text{평균}) / \text{표준편차}$
 - 평균은 0, 표준편차는 1이 되게 함
- (4) 활용 예
 - A는 SAT 시험에서 1800 (out of 2400) 을 받음
 - B는 ACT 시험에서 24 (out of 36) 을 받음
 - SAT 평균은 1500, 표준편차는 300
 - ACT 평균은 21, 표준편차는 5
 - A의 Z-점수는 1, B는 0.6.
 - 결국 A가 더 잘했음

1) 데이터사분할


(1) 지도학습에서 필수

- 학습용/평가용, 입력값/출력값으로분할
- 나누는 순서는 상관없음




2) Boston데이터 입력값 상자그림

(1) Boston 데이터 입력값 상자그림



1) DNN 설계도

(1) DNN 설계도




- 2,000개와 1,000개는 실험적으로 정해짐

2) ReLU 활성화함수

(1) Rectified Linear Unit


- 수학적 정의: $F(x) = \max(0, x)$
- 음수를 0으로 만들
- 도움이 되지 않는 뉴런을 비활성화함
- 기울기 소실 문제가 적음



1) 경사하강법

(1) Statistical Gradient Descent (SGD)

- 지도학습에서 가중치를 조정하는 대표적 방법
- 함수의 기울기(경사)를 구하여 낮은 쪽으로 이동



2) 평균 제곱 오차

(1) Mean Square Error (MSE)

예측값과 정답과의 차이 (= 오차)의 제곱의 평균

$$MSE = \frac{1}{n} \sum_{i=1}^n (predict - truth)^2$$

완벽한 예측의 경우 MSE는 0
오차가 커지면 MSE가 커짐 제곱오차들
의 평균: 큰 오차들에 더 민감

1) Evaluate & Predict

(1) Keras evaluate 함수

- 학습된 DNN을 평가할 때 사용
- 학습용 데이터 입력과 출력을 동시에 사용
- X_test와 Y_test 사용


(2) Keras predict 함수

- 학습된 DNN으로 추측할 때 사용
- 새로운 데이터를 사용
- 새로운 데이터 부재 시: 학습용 데이터 입력만 사용
- X_test 사용

2) Seaborn Regplot

(1) 데이터 시각화에 많이 사용

- 산포도와 선형 모델을 동시에 구현



1) 실습문제 1/7

**MY_EPOCH 하이퍼 파라미터를
0으로 바꾸고 실험을 반복하세요.**

결과가 어떻게 바뀌나요?

2) 실습문제 2/7

**MY_BATCH 하이퍼 파라미터를
16으로 바꾸고 실험을 반복하세요.**

결과가 어떻게 바뀌나요?

1) 실습문제 3/7

**500개 뉴런을 가진 은닉층 두 개를
마지막 단에 추가하고 실험을 반복하세요.**

결과가 어떻게 바뀌나요?

2) 실습문제 4/7

Z-점수 정규화를 건너 뛰고 실험을 반복하세요.

결과가 어떻게 바뀌나요?

2) 실습문제 5/7

학습용 데이터의 하반부를 제거하고 실험을 반복하세요.

결과가 어떻게 바뀌나요?

2) 실습문제 6/7

**Dataset에서 CRIM (범죄율) 요소를 제거하고 실험을
반복하세요.**

결과가 어떻게 바뀌나요?

2) 실습문제 7/7

**집값을 예측하는 것에서, 집의 나이를 추측하는 것으로
코딩을 바꾸어 보세요.**

어떤 문제가 난이도가 높은가요?

6.2 DNN으로 심장병 판별하기

3) UCI Heart Disease Dataset

(1) 303명 환자의 데이터 (www.kaggle.com)

- 14가지 항목의 정보 제공




3) UCI Heart Disease Dataset

(2) 14가지 항목

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	심장병 여부 Heart Disease
심장병 X	63	1	1	145	233	1	2	150	0	2.3	3	0	6	0
심장병 O	67	1	4	160	286	0	0	108	1	1.5	2	3	3	1

- age: 나이
- sex: 성별, 0: 여성, 1: 남성
- cp: 가슴 통증 유형(4가지)
- trestbps: 안정 혈압
- chol: 좋은 콜레스테롤(HDL)
- fbs: 공복 혈당(0: 120 보다 낮음, 1: 반대)
- restecg: 안정 심전도 (3가지, 0: 정상)
- thalach: 최대 심박동 수
- exang: 운동 시 협심증상(0: 아니오, 1: 예)
- oldpeak: 운동시 유발되는 ST depression
- slope: 운동 시 ST segment 기울기
- ca: 형광 투시되는 주요 혈관 수(0-3)
- thal: 결함 종류(3: 정상, 6/7: 비정상)
- HeartDisease: 심장병? 0 = no, 1 = yes



-
- 심층 신경망 : DEEP NEURAL NETWORK(DNN)
 - 심층 신경망 (DNN)은 ANN 중 은닉층의 갯수가 많아 복잡한 비선형적 관계를 설명하는데 효과적임
 - 순방향 계산에서는 입력을 왼쪽에서 받아 오른쪽으로 진행하며 뉴런의 출력을 계산함
 - 역전파 알고리즘은 역방향으로 진행하며 뉴런과 시냅스의 가중치를 보정함


2. 기울기 유실 문제

- 기울기 유실의 증상
 - 인공신경망에 있는 가중치들이 더 이상 변하지 않는 현상임
 - 활성화 함수의 편미분 값이 0에 가까워지면서 발생함
 - 활성화 함수를 대체함으로써 문제를 어느 정도 해결 가능함

1) Pandas 데이터 프레임

(3) 지도학습에서 필수

- 각 데이터는 입력값, 출력값, 정답을 소유



- 인공신경망은 입력값을 받아 순방향(왼→오)으로 진행하며 출력값을 계산
- 출력값이 3.5이라면 정답 3과 오류 0.5발생
- 역전파하면서 뉴런과 시냅스의 가중치를 보정

1) Z-점수 정규화

(1) 머신러닝 알고리즘

- 데이터의 특정 패턴을 찾음
- 새로운 값을 예측

(2) 심장병 데이터의 예

- 안정혈압: 94~200
- 울드피크: 0~6.2

▶ 기계학습을 할 때 범위가 더 넓은 요소가 큰 영향을 미침

‘제트점수 정규화 진행 이유’

1) Z-점수 정규화

(3) Z-점수 = $(X - \text{평균}) / \text{표준편차}$

- 평균은 0, 표준편차는 1이 되게 함


(4) 활용 예

- A는 SAT 시험에서 1800 (out of 2400) 을 받음
- B는 ACT 시험에서 24 (out of 36) 을 받음
- SAT 평균은 1500, 표준편차는 300
- ACT 평균은 21, 표준편차는 5
- A의 Z-점수는 1, B는 0.6.
- 결국 A가 더 잘했음

2) 상자그림 (Box Plot)

(1) 데이터의 특징을 5가지 값으로 시각적 표현


- 사분위수 (Q1, 중앙값, Q3)와 최소값, 최대값




3) Heart Disease 데이터 상자 그림

(1) 특이점을 보이는 요소들 존재

- 기계학습에 도움이 안될 가능성 존재




1) DNN 설계도



2) Tanh 활성화 함수

(1) 쌍곡선 함수 중 하나


- $[-1, 1]$ 데이터 스케일링과 자주 짝을 이룸
- 뉴런 출력값의 양수 대 음수 균형을 맞춤
- DNN의 은닉층에서 많이 사용
- Sigmoid 활성화 함수의 기울기 유실 문제 보완



3) Sigmoid 활성화 함수

(1) 딥러닝에서 가장 많이 쓰이는 활성화 함수


- Step function을 대체: 전 구간에서 미분 가능
- 장점: 미분 계산이 간단, $s'(x) = s(x)\{1-s(x)\}$
- 단점: 기울기 유실 문제



1) 경사 하강법

(1) Stochastic Gradient Descent (SGD)

- 지도학습에서 가중치를 보정하는 대표적 방법
- 함수의 기울기 (경사) 를 구하여 낮은 쪽으로 이동



2) 평균 제곱 오차

(1) Mean Square Error(MSE)

- 예측값과 정답과의 차이 (= 오차)의 제곱의 평균


$$MSE = \frac{1}{n} \sum_{i=1}^n (predict - truth)^2$$

- 완벽한 예측의 경우 MSE는 0
- 오차가 커지면 MSE가 커짐
- 제곱오차들의 평균: 큰 오차들에 더 민감

2) Torch 텐서 vs. Numpy 행렬

(1) 둘 다 n-차원 행렬


	PyTorch 텐서	Numpy n-차원 행렬
연동 package	PyTorch	Python의 모든 package
GPU 지원	yes	no
장점	속도, PyTorch와 연동	무게, 안정성, 역사
단점	미완성, 무게	속도



2) 혼동 행렬(Confusion Matrix)

		[실제값]	
		Positive	Negative
[예측값]	Positive	 True positive Positive인 것을 Positive로 예측하여 True	 False positive (Type I error) Negative인 것을 Positive로 예측하여 False
	Negative	 False negative (Type II error) Positive인 것을 Positive로 예측하여 False	 True negative Negative인 것을 Positive로 예측하여 True

3) F1 점수



$$F1\ score = \frac{2 \times precision \times recall}{precision + recall}$$

1) 실습문제 1/7

임의의 수 생성 알고리즘의 씨앗을 제거해 보세요.

어떤 결과를 얻나요?

2) 실습문제 2/7

SGD 대신 RMSprop 최적화 함수를 사용해 보세요.

어떤 결과를 얻나요?

1) 실습문제 3/7

**5,000개의 뉴런을 갖는 새 은닉층을 오른쪽에 추가해
보세요.**

어떤 결과를 얻나요?

2) 실습문제 4/7

Tanh 활성화 함수 대신

ReLU 활성화 함수를 사용해 보세요.

어떤 결과를 얻나요?

1) 실습문제 5/7

Z-점수 정규화를 건너 뛰어 보세요.

어떤 결과를 얻나요?

2) 실습문제 6/7

심장병 데이터에서, fbs와 chol 컬럼을 삭제해 보세요.

어떤 결과를 얻나요?

2) 실습문제 7/7

303개의 데이터 중 처음 100개만 사용해 보세요.

어떤 결과를 얻나요?